

Relatório de Proposta: Análise Estatística de Desempenho no Campeonato Brasileiro Série A (2003–2023)

Grupo:

–

Lucas de Oliveira Ferreira

Caio Henrique de Miranda Onofre

Joao Pedro Cordeiro Contarini

João Pedro Coutinho Capelão

–

Disciplina: Introdução à Ciência de Dados

Instituição: Universidade Federal de Minas Gerais (UFMG)

Tema e Ideia Central

O projeto propõe investigar os principais fatores que influenciam o rendimento das equipes na Série A do Campeonato Brasileiro no período de 2003 a 2023. A ideia central é cruzar variáveis de desempenho técnico (chutes, faltas e idade média do time titular) com aspectos de gestão (permanência de treinadores) para identificar padrões estatísticos associados ao sucesso ou insucesso na tabela de classificação.

Descrição do Conjunto de Dados

A base escolhida é o conjunto de dados do **Campeonato Brasileiro Série A**, disponibilizado pela **Base dos Dados**. O repositório contém informações detalhadas de partidas, incluindo estatísticas coletivas de cada time, técnicos, idade média e classificação.

Conteúdo principal: estatísticas por partida (gols, chutes, faltas, escanteios, defesas etc.), técnicos mandante e visitante, idade média dos titulares e colocação dos times.

Período analisado: 2003 a 2023 (considerando a disponibilidade dos dados).

Link de acesso:

<https://basedosdados.org/dataset/c861330e-bca2-474d-9073-bc70744a1b23?table=18835b0d-233e-4857-b454-1fa34a81b4fa>

Perguntas de Pesquisa e Metodologia

A. A quantidade de chutes ao gol é um bom indicador do rendimento de um time?

Atributos úteis: `chutes_mandante`, `chutes_visitante`, `chutes_fora_mandante`, `chutes_fora_visitante`, `gols_mandante`, `gols_visitante`, `resultado` (calculado a partir dos gols) e `colocacao_mandante / colocacao_visitante`.

Metodologia: Pretendemos explorar a relação entre o volume de chutes (total e fora) e o desempenho da equipe por meio de análises de correlação e técnicas de regressão. Durante a Análise Exploratória de Dados (EDA), geraremos visualizações para entender melhor esse relacionamento e discutiremos quais modelos estatísticos seriam mais adequados.

B. O tempo de permanência de um treinador no cargo impacta o rendimento da equipe?

Atributos úteis: `tecnico_mandante`, `tecnico_visitante`, `data`, `ano_campeonato`, `colocacao_mandante`, `colocacao_visitante` e campos que permitam calcular a duração da passagem (como sequência de rodadas por técnico).

Metodologia: Planeja-se realizar uma análise de longevidade dos treinadores, agrupando-os por períodos de permanência (curta, média e longa duração). Compararemos o aproveitamento de pontos médio (PPM) entre esses grupos e avaliaremos a diferença por meio de testes estatísticos. A ideia é discutir em que medida a estabilidade técnica se reflete em melhores resultados.

C. A quantidade de faltas cometidas interfere no rendimento do time?

Atributos úteis: `faltas_mandante`, `faltas_visitante`, `colocacao_mandante`, `colocacao_visitante`, `gols_mandante` / `gols_visitante`.

Metodologia: Pretendemos investigar se existe correlação entre o número de faltas cometidas e o desempenho da equipe (posição na tabela). Usaremos análises bivariadas e multivariadas para explorar tanto efeitos negativos (possíveis desfalques ou punições) quanto possíveis aspectos positivos (agressividade na marcação). Essa análise será refinada conforme observarmos os padrões nos dados.

D. Qual a média de idade típica de um time com melhor rendimento?

Atributos úteis: `idade_media_titular_mandante`, `idade_media_titular_visitante`, `colocacao_mandante`, `colocacao_visitante`, `ano_campeonato`.

Metodologia: Analisaremos a idade média da equipe titular dos times que terminaram entre os melhores colocados (ex.: G4) em cada temporada. Usaremos estatística descritiva (média, mediana e desvio padrão) para comparar o perfil etário dos times de melhor desempenho com os de pior colocação e discutiremos possíveis interpretações sobre o equilíbrio entre experiência e juventude.

Planejamento de Próximos Passos

- Extração e limpeza dos dados no BigQuery (filtro do período desejado, criação de variáveis derivadas como resultado da partida e tratamento de valores ausentes).
- Análise Exploratória de Dados (EDA): histogramas, boxplots, correlogramas e visualizações iniciais para confirmar a qualidade e distribuição das variáveis.
- Aplicação de técnicas estatísticas (correlações, testes de hipótese, regressão etc.) conforme as perguntas de pesquisa.
- Interpretação dos resultados à luz do contexto do futebol brasileiro, com espaço para discussão de limitações e ideias futuras.

Cronograma

- **Abril e Maio/2026** – Desenvolvimento das análises estatísticas, testes e construção de visualizações.
- **04 a 08 de Maio** – Entrevista 2: discussão sobre o andamento do projeto e evolução das análises.
- **Junho/2026** – Finalização dos resultados e conclusões.
- **Até junho (véspera da apresentação)** – Gravação do vídeo pitch de até 10 minutos.
- **15 e 18 de Junho** – Entrega do relatório final e defesa da apresentação.